연세대학교 공학대학원 인공지능학과 · 최신딥러닝이론및응용

최신딥러닝이론및응용 강의 콘텐츠로 검증하는 자가 진화 LLM 하네스의 학습 효과

오버피팅인가, 진짜 개선인가 — 개선분을 O·T·G 로 분해해 가린다

14조 · EvoLecture · 2026-11-23 중간발표 · 발표 우샛별 · 손재완 · 한동윤

https://wukong-daima.github.io/team14-project/

질문

모델 가중치를 바꾸지 않는 자가 진화 하네스가 학습 콘텐츠를 실제로 개선하는가?

개선분을 수업에서 배운 대로 쪼개면 무엇이 남는가?

$$\Delta = O + T + G$$

O 연습 문제만 외워서 오른 점수 · T 여러 번 풀게 해서 오른 점수(호출 수) · G 위 둘을 빼고 남는 실력 ← 우리가 알고 싶은 것. 8주차 HDA 분해를 우리 루프에 그대로 적용

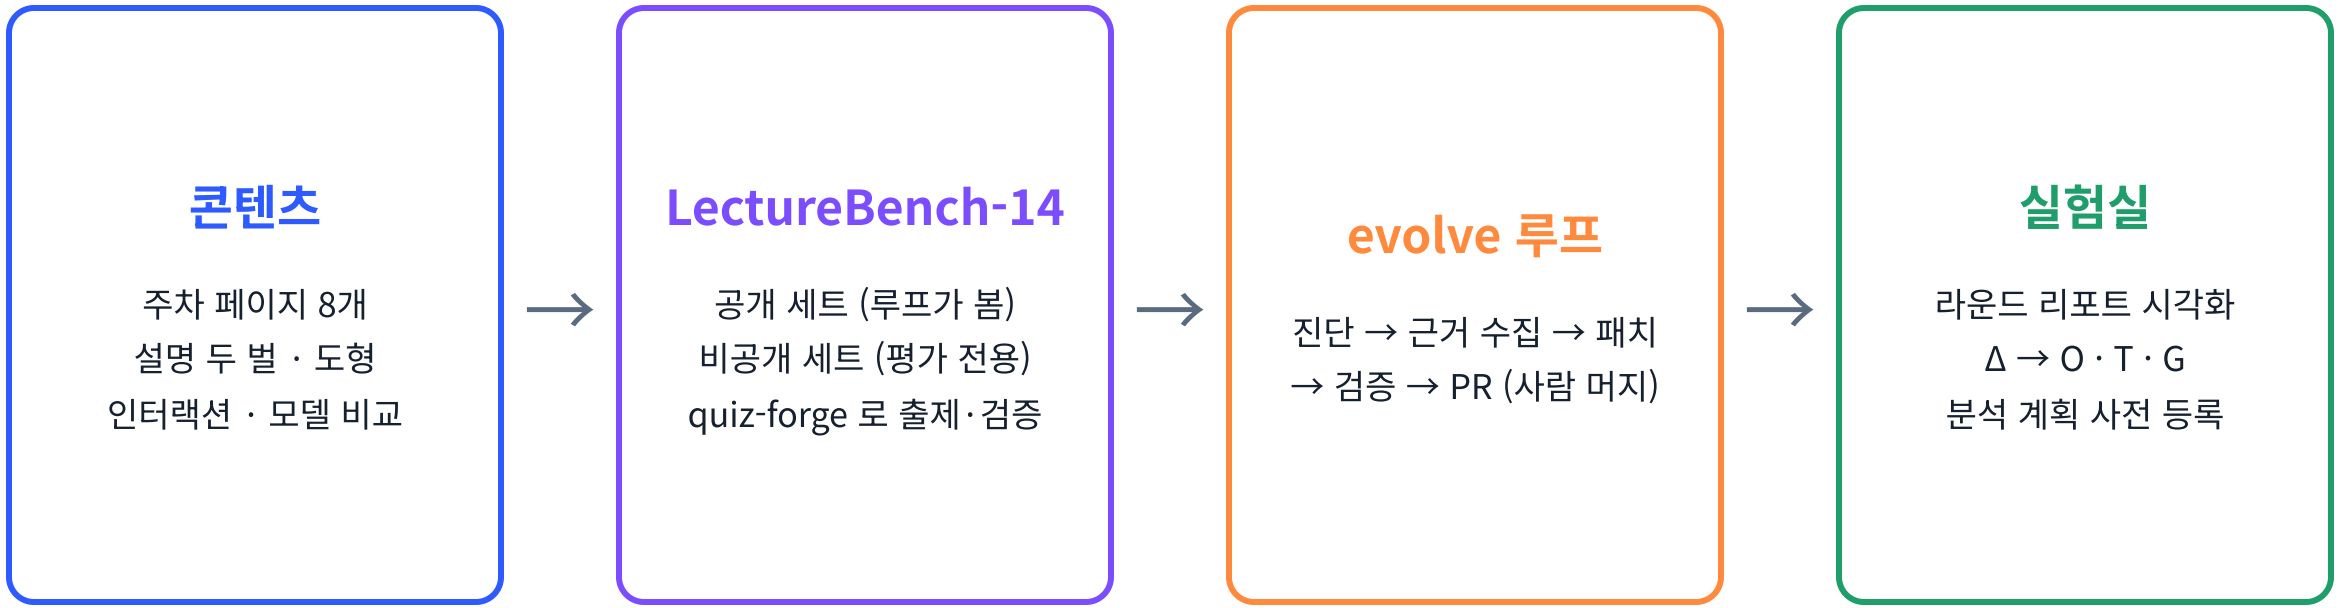
- 부질문 1 · 보상에서 출처 검증 항을 빼면 루프는 어떻게 달라지는가 (9주차 '부정확한 리워드', ablation)
- 부질문 2 · 수업에서 배운 기법이 Claude 의 행동으로 관측되는가 (테스트타임 스케일링, pass@k, 하네스 효과)

왜 이 질문인가 — 수업이 남긴 세 가지 경고

- **1주차** 정의된 문제를 푸는 AI에서, 문제를 스스로 정의하고 자가 개선하는 에이전트로
- **8주차** 하네스 최적화로 보고된 향상의 상당 부분이 오버피팅·호출 수 증가였다 (ALFWorld 98%). $\Delta = E - B = O + T + G$
- **9주차** 리워드가 부정확하면 루프는 엉뚱한 방향으로 진화한다. pass@k 로 망가진 문제를 찾는다
- **우리** 이 경고를 우리 자신의 학습 사이트에서 재현·검증한다. 학습자(모델)는 그대로 두고 공부의 하네스만 바꾼다

다른 '자기 개선 루프' 주제와의 차이: 루프를 만드는 데서 멈추지 않고, 그 루프가 만든 향상이 진짜인지 쪼개서 가린다.

실험 장치 한 장



풀이자 = 작은 모델(사이트 본문만 봄) · 제안자 = 큰 모델(문제를 보지 않음) · 모든 숫자는 리포트 JSON 을 그대로 읽는다

데모 ① 사이트 — 만져보며 배우는 콘텐츠

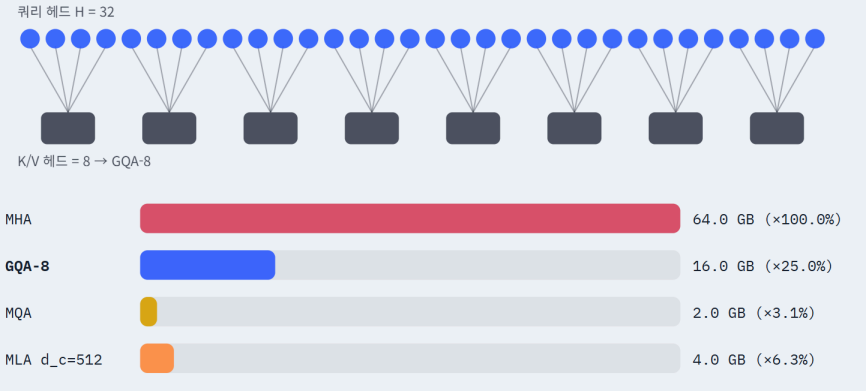
🎮 KV 캐시 계산기 — MHA / GQA / MQA / MLA

슬라이더를 움직이면 헤드 연결도와 KV 캐시 메모리가 바뀝니다. "KV 그룹 수"를 1로 내리면 MQA, 헤드 수와 같게 올리면 MHA입니다.

쿼리 헤드 수 H 32 | KV 그룹 수 g (GQA) 8 | 시퀀스 길이 L 128K

레이어 수 32 | d_head 128 | 정밀도 FP16/BF16 (2B)

MLA 잠재 차원 d_c: 512 (DeepSeek-V2) | 프리셋: 직접 설정



시퀀스 128K 토큰 · 32층 · d_head 128 · FP16
GQA-8 KV 캐시 = **16.0 GB** → 80GB GPU 1장의 20.0% (KV 캐시만)
MHA 대비 4.0배 절약 · MLA는 16.0배 절약

공식: KV = 2 × layers × n_kv × d_head × L × bytes. MLA는 layers × d_c × L × bytes 로 근사했습니다 (DeepSeek-V2의 분리된 RoPE 키 차원은 제외). GPU 장수는 KV 캐시만 기준이며 가중치는 포함하지 않습니다.

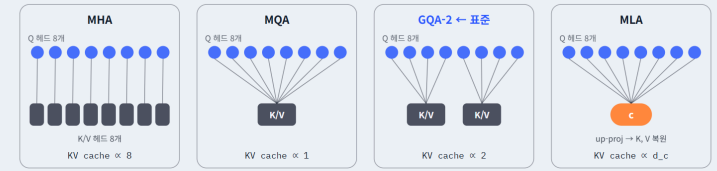
- 주차 페이지 8개 (1·2·3·4·6·8·9·10주차), 주차당 대표 인터랙션 1개
- 예: 2주차 KV 캐시 계산기 — MHA → GQA → MQA → MLA 메모리 비교
- 모든 설명은 전공 / 중학생 두 벌, 버튼 하나로 전환 (아래)
- 모델 비교는 공개 자료만, 모르면 '비공개'. 요약본과 원본이 다르면 정정 박스 (예: DeepSpeed → DeepSeek Sparse Attention)

CONCEPT 02 · p.17, 22–27

MHA → MQA → GQA: KV 캐시와 성능의 줄다리기

🧒 중학생 버전

교실에 학생(쿼리) 32명이 있고 각자 교과서(K/V)를 한 권씩 가지면 사물함이 꽉 차요(MHA). 교과서 한 권을 반 전체가 돌려보면 사물함은 비지만 줄 서느라 공부가 안 돼요(MQA). 4명당 한 권씩 모둠으로 나누면 적당해요(GQA). 요즘 AI는 거의 다 이 모둠 방식을 써요.



쿼리 헤드 8개 기준. K/V 상자 수가 곧 KV 캐시 크기입니다. MLA는 K/V 대신 작은 잠재 벡터 c만 저장하고 필요할 때 복원합니다.

2주차 페이지 · 로컬 서버 라이트 테마 · wukong-daima.github.io/team14-project

데모 ② 실험실 — 리포트를 그대로 읽는 페이지

질문	재학습 없는 자가 진화 루프가 학습 콘텐츠를 실제로 개선하는가? 개선분은 O(오버피팅)·T(테스트타임)·G(일반화) 중 어디서 오는가?
보상 R	`R = 0.6 · Acc_public + 0.4 · SourcePass`. 비공개 세트 정답률은 보상에 쓰지 않는다.
분해	`Δ = Acc_after − Acc_before` (공개), `O = Δ_public − Δ_heldout`, `T` = 호출 수 동일 설계라 0 (호출 수 효과는 E1·E2 로 별도), `G = Δ − O − T`
채택 기준	유출 검사 통과 · HTML 정상 · `R_after > R_before`. 채택돼도 사람이 PR 을 검토한다.
표본 목표	공개 150+ · 비공개 50+ 문항, 라운드 3회 이상, 풀이 시드 3개 평균±표준편차
예상 결과 (미리 적어 둠)	O가 Δ의 절반 이상일 가능성이 크다. 그 경우 "수업(8주차)이 경고한 현상을 재현했다"로 보고하며 결과를 숨기지 않는다.
한계	풀이자는 사람이 아니라 모델(haiku)이다. 정답률은 "콘텐츠가 풀이자에게 주는 정보량"의 대리 지표다.

실험실 /lab/ · 분석 계획 표 · 로컬 서버 라이트 테마

- evolve/reports/*.json 을 그대로 읽어 그린다. 숫자는 사람이 손대지 않는다
- 맨 위에 분석 계획을 결과 전에 고정 (왼쪽)
- 비공개 세트가 없으면 O·G 는 비워 두고 '개선'을 주장하지 않는다
- 현재 라운드·실험 리포트 0건 → 빈 상태 (아래)

1. 라운드

아직 실행된 라운드가 없습니다. `python evolve/round.py --weeks week02,week04,week08` 을 실행하면 여기에 나타납니다.

2. 행동 실험 (Claude 와 수업 방식 비교)

E3 자료 없음/브리프/페이지 조건 정답률 · E2 pass@k vs pass^k · E1 effort(테스트타임 스케일링). 해석은 공개 문서 범위에서만 합니다.

아직 실험 결과가 없습니다. `python evolve/experiments.py e3 --weeks week02,week04,week08`

벤치마크 LectureBench-14

공개 / 비공개 세트

- 공개 세트: 사이트와 루프가 봄. 지금 자동 채점 57문항(객관식·계산) + 서술형 11 (2·4·8·9주차). 목표 150+
- 비공개 세트: 별도 비공개 저장소, 평가 전용. 루프는 보지 않고, 조원도 콘텐츠를 쓸 때 보지 않음. 목표 50+ (현재 0)
- 같은 개념 격자에서 뽑되 문장·수치를 다르게
- 판정: 공개 ↑ · 비공개 ↑ → G 진짜 개선 / 공개 ↑ · 비공개 그대로 → O 오버피팅

출제 하네스 quiz-forge (8주차 Autodata agent 구조)

- 출제자 → 약한 풀이자(자료 없이) / 강한 풀이자(자료 보고) → 검증자
- 약한 풀이자가 늘 맞히면 너무 쉬운 문제, 강한 풀이자가 못 풀면 결함 문제
- 정답 위치 재배치 · 보기 길이 편향 검사 · 실패 사례 기준
- 9주차: 후보 28문항 → 채택 22 · 탈락 6
- 9주차 pass@k 연계 (E2): k번 풀어도 거의 못 맞히는 문항 = 결함 후보 → quiz-forge 재검증

2·4·8주차 시드 39문항은 아직 quiz-forge 검증 전 — 비공개 세트와 함께 출제·검증 예정

진화 루프 · 보상 · 유출 방지

한 라운드

- ① 진단 — 약한 풀이자가 공개 세트를 풀어 오답이 몰린 개념 추출
- ② 근거 수집 — 브리프 · 논문 · 공식 문서에서 근거 후보
- ③ 패치 — 해당 주차 카드에 보강 설명 (전공/쉬운 + 출처)
- ④ 검증 — 유출 검사 · HTML 검사 · R 재계산
- ⑤ PR — 통과한 패치만. 사람이 검토·머지 (자동 머지 없음)
- 예시 · 성적표 = 시험 점수 60 + 근거 점수 40. 시험 점수만 보면 본문에 '답: 3번'을 적는 꼼수가 통하므로, 근거에도 점수를 준다

보상과 유출 방지 3규칙

- R = 0.6 · Acc_public + 0.4 · SourcePass
- 비공개 정답률은 보상에 쓰지 않는다
- 규칙 1 · 풀이자에게 주는 페이지에서 예상 문제 제거
- 규칙 2 · 제안자는 문제를 보지 않는다 (약한 개념 이름만)
- 규칙 3 · 패치가 문제 문장·보기와 25자 이상(또는 60%) 겹치면 라운드 기각
- 그래도 새면 → 비공개 점수가 안 따라 올라 O 로 드러난다

9주차 '부정확한 리워드' 대응: 정답률만 보상이면 정답을 콘텐츠에 써넣는 리워드 해킹이 가능하다

측정 · 분해 · 신뢰구간 · 채택 기준

분해 (8주차 HDA 를 우리 루프에)

- Δ = Acc_after − Acc_before (공개 세트)
- O = Δ_public − Δ_heldout — 공개 문제에만 맞춘 몫
- T = 0 — 전/후 풀이 호출 수가 같은 설계. 호출 수 효과는 E1·E2 로 별도 측정
- G = Δ − O − T — 남는 진짜 개선
- 비공개 세트가 없으면 O·G 는 null → '개선'을 주장하지 않는다

통계와 채택

- 문항 단위 부트스트랩 95% 신뢰구간
- 구간이 겹치면 '유의한 개선'이라 부르지 않는다
- 풀이 시드 3개 평균 ± 표준편차
- 채택 기준: 유출 0 · HTML 정상 · R 상승
- 채택돼도 사람이 PR 을 검토한다
- 예시 (설명용 가상 수치 — 실측 아님): 공개 +10%p · 비공개 +4%p → O = 6 · T = 0 · G = 4
- 왜 결과 전에 고정하나: 결과를 본 뒤 기준을 바꾸면 그 자체가 오버피팅 → 다음 장 사전 등록표

행동 실험: E1 effort(low→xhigh) vs 정답률·비용 · E2 pass@k vs pass^k(결함 문항 탐지) · E3 자료 없음/브리프/페이지

사전 등록 — 결과를 보기 전에 고정한 것

항목	고정값
보상	R = 0.6·Acc_public + 0.4·SourcePass. 비공개 정답률은 보상에 쓰지 않음
분해	O = Δ공개 − Δ비공개 · T = 0 (호출 수 동일) · G = Δ − O − T
채택	유출 0 · HTML 정상 · R 상승 · 사람이 PR 검토
표본	공개 150+ · 비공개 50+ · 라운드 3회 이상 · 풀이 시드 3개 평균±표준편차
행동 실험	E1 effort(low→xhigh) · E2 pass@k vs pass^k · E3 자료 없음/브리프/페이지
예상 결과	O 가 Δ 의 절반 이상일 가능성이 크다. 그 경우 '수업이 경고한 현상을 재현했다'로 보고하고 숨기지 않는다
ablation	보상에서 SourcePass 항을 뺀 루프를 같은 조건으로 돌려 비교

결과가 '개선 없음'이어도 그대로 보고한다

지금까지 결과 — 수치는 아직 없습니다

항목	진행 내용	상태
실제 라운드	0회 · 11/28까지 라운드 3회 이상 실행 예정 (첫 라운드: 2·4·8주차, full 보상 + acc-only ablation)	실행 예정
전/후 점수 · O·T·G	리포트 없음 → 수치를 싣지 않음	실행 예정
evolve 파이프라인	진단·풀이·제안·검증·라운드·실험 스크립트. mock 풀이자로 끝까지 실행 확인 (정답률 의미 없음)	mock 검증 완료
실행 환경	구독(claude -p) / API 백엔드 · 비용 상한 · GitHub Actions 워크플로 작성	구현 완료
공개 세트	자동 채점 57 + 서술형 11 (2·4·8·9주차)	진행 (목표 150+)
비공개 세트	0문항 → 지금은 O·G 계산 불가	착수 예정 (목표 50+)
행동 실험 E1~E3	결과 없음	실행 예정

원칙: 리포트가 없거나 mock 이면 숫자를 넣지 않는다. 실행 후 리포트를 커밋하면 실험실 페이지에 자동 표시

일정 · 분업 · 남은 일

날짜	할 일	상태
10/31 ~ 11/10	사이트 7주차 · 출제 하네스 quiz-forge · 9주차 문항 검증	완료
11/11 ~ 11/14	10주차 페이지 · 루프 스크립트 · 실험실 · 분석 계획 사전 등록 · 시드 문항 (공개 세트 68문항)	완료 (루프는 mock 검증)
11/15	제안 제출	완료
11/23	중간발표: 설계 · 장치 · 진행 현황	예정
11/28	Actions 자동화 · 라운드 3회 이상 · 공개 150 · 비공개 50 · E1~E3	예정
11/30 · 12/7	최종발표: 분해 결과 · ablation · 한계	예정

담당 A 벤치마크(문제 은행·quiz-forge) · 담당 B 진화 루프(evolve·Actions) · 담당 C 행동 실험·분석·발표 · 통합 리뷰·머지

한계와 정직성 규칙

- **풀이자는 모델** 정답률은 '콘텐츠가 풀이자에게 주는 정보량'의 대리 지표. 가능하면 조원 3명이 비공개 20문항을 전/후로 풀어 보조 근거 (콘텐츠 작성에는 쓰지 않음)
- **표본이 작다** 신뢰구간을 항상 함께 보고. 150/50 이 될 때까지 '개선'을 주장하지 않는다
- **결과가 '개선 없음'일 수 있다** 그것도 결과. 수업의 '겉보기 향상 대부분이 O'와 일치하면 그대로 보고
- **공개 자료만** 모델 비교는 공개 문서 범위. 모르면 '비공개'. 요약본 오류는 정정 박스로
- **강의 원본 비공개** PDF·슬라이드 이미지는 저장소에 올리지 않는다

https://wukong-daima.github.io/team14-project/ · github.com/wukong-daima/team14-project

Q&A — 예상 질문

Q1 ~ Q3

- **Q1 모델 풀이자의 정답률이 곧 콘텐츠 품질인가?** 아니다. '콘텐츠가 풀이자에게 주는 정보량'의 대리 지표로만 해석한다. 가능하면 조원 3명이 비공개 20문항을 전/후로 풀어 보조 근거로 쓴다
- **Q2 T 를 0 으로 둬도 되나?** 분해 식 안에서는 전/후 호출 수·설정을 고정해 T = 0. 호출 수·추론량 효과는 E1(effort)·E2(pass@k)에서 따로 측정. 페이지가 길어져 입력이 늘어나는 효과는 전/후 토큰 수를 함께 기록
- **Q3 문항 수가 적은데 무엇을 말할 수 있나?** 지금은 아무것도 주장하지 않는다. 공개 150+ · 비공개 50+ · 라운드 3회 · 시드 3개를 채우고 신뢰구간이 겹치지 않을 때만 '유의한 개선'. 중간발표의 기여는 장치와 프로토콜

Q4 ~ Q5

- **Q4 SourcePass 는 어떻게 판정하나? 그것도 부정확한 리워드 아닌가?** 맞다, 지금은 출처 배지 집계로 근사(실제 대조 아님). 그래서 이 항을 뺀 ablation 을 부질문으로 두었고, 실제 주장-출처 대조로 바꿀지는 검토 중
- **Q5 결과가 'O 가 대부분'이면 실패인가?** 아니다. 8주차 경고를 우리 시스템에서 재현한 것이고, 그렇게 보고하겠다고 사전 등록했다. 그런 결과를 잡아내는 측정 프로토콜이 기여